

Python数据可视化应用与实践

—— 实验一：Python基础编程实践

目 录

CONTENTS

01 实验目的

02 实验内容

03 实验原理回顾

04 实验步骤

05 实验要点

06 实验要求与思考题

一、实验目的

本次实验要达到的五个目标

- 配置并验证环境：独立完成 Anaconda / Jupyter 启动，导入 NumPy、Pandas 并验证版本（呼应第 1 章）。
- 巩固 Python 基础语法：熟练使用条件判断、循环、函数定义与列表推导式处理简单数据。
- 掌握 NumPy 数组基础：能够创建、查看属性、转置重塑，并按轴做向量化统计运算。
- 打通 Pandas 数据处理全链路：基于实验专用脏数据，完成 读取→概览→去重→类型转换→筛选→缺失/异常→聚合透视→保存（呼应第 2 章）。
- 养成可复现、整洁的数据处理习惯：关键步骤加注释、保留中间输出、说明处理依据。

贯穿案例：实验一_销售流水_原始.csv（1012 行 × 6 列，刻意保留真实导出时的脏乱问题）

二、实验内容

三个递进式任务

- 任务一 · 环境与语法热身：验证 Jupyter/NumPy/Pandas 环境，练 Python 基础语法。
- 任务二 · NumPy 基础：数组创建、属性、转置重塑、按轴向量化统计。
- 任务三 · Pandas 数据处理：用脏数据走完 读取→概览→去重→类型转换→筛选→缺失/异常→聚合透视→保存全链路。
- 任务四 · Matplotlib绘图 （选做）

一个数据集贯穿：先「脏」后「净」，全程复用同一份订单流水，贴合真实数据工程。

二、实验内容

数据：实验一_销售流水_原始.csv 文件（1012 行 × 6 列）

order_id	order_time	store	category	amount	quantity
D260301001	03-01-2026 09:42	B店	服饰	664.13	3
D260301002	2026/3/1 11:18	A店	服饰	320元	2
D260301003	2026/3/1 11:23	A店	家电	¥630.14	1
D260301004	2026/3/1 12:04	B店	家电	196元	2
D260301005	2026/3/1 15:28	A店	食品	574元	1
D260301006	03-01-2026 16:19	B店	家电	¥509.84	3
D260301007	2026/3/1 16:33	B店	图书	¥533.34	5
D260301008	2026/3/1 17:04	c店	食品	¥278.22	1
D260301009	2026/3/1 18:13		家电类	¥199.53	6
D260301010	03-01-2026 20:22	B店	食品	692.77	3
D260301011	2026/3/1 20:30	C店	服饰	¥333.79	1
D260302001	03-02-2026 12:11	B店	家电	288.47	1
D260302002	2026/3/2 12:53	A店	图书	¥213.91	1
D260302003	2026/3/2 14:27	A店	服饰	¥514.17	1
D260302004	03-02-2026 15:49	B店	服饰	593.32	2
D260302005	2026/3/2 18:28	A店	服饰	¥742.80	1
D260302006	2026/3/2 19:50	B店	服饰	¥350.13	2
D260302007	2026/3/2 20:08	A店	图书	¥556.61	3
D260302008	03-02-2026 20:33	B店	食品	641.76	4
D260302009	03-02-2026 21:05	A店	家电	¥629.06	3
D260302010	2026/3/2 21:27	A店	图书	¥754.83	3
D260303001	2026/3/3 9:05	A店	服饰	722.67	1
D260303002	2026/3/3 9:23	A店	家电	400.96	5

潜在的问题有：

问题类型	典型表现
重复值	同一 order_id 出现两次（整行完全重复）
缺失值	store / category / amount / quantity 为空
类型错乱	amount 存成 "¥1,280.00" / "1280元"；quantity 存成 "2.0"
口径不一致	store：" A店"/"a店"/"A门店"；category：" 家电 "/"家电类"
异常值	amount：8 个负值 + 3 个离谱极值(999999/88888/77777)；quantity：5 个 0 + 3 个 −1
时间格式混杂	order_time 混用 ISO / 斜杠无前导零 / 美式月-日-年

三、实验原理回顾

把课上讲的"为什么"落到实操

- Ch1 工具链：Anaconda（集成 180+ 科学计算包）→ Jupyter（交互式、代码/文本/图混合）→ 三大库 Matplotlib / Seaborn / pyecharts。
- Ch2 数据处理四步法：读取(read) → 概览(explore) → 处理(clean) → 验证(verify)。
- 关键 API 速查：
  - 读取概览：`read_csv` / `shape` / `info()` / `describe()` / `isnull().sum()`
  - 类型：`to_datetime()` / `astype("category")`
  - 筛选：布尔索引 / `query()` / `dt.year` 等时间访问器
  - 清洗：`fillna()`（中位数/众数/ffill） / `dropna()` / `interpolate()` / `clip()`
  - 聚合：`groupby().agg()` / `pivot_table(margins=True)`
  - 保存：`to_csv(index=False, encoding="utf-8-sig")`

读 → DataFrame → 写：所有读取函数都返回 DataFrame，后续一切处理都在这个对象上完成。

四、实验步骤

任务一：环境与语法热身

启动 Jupyter，确认 NumPy/Pandas 可导入

```python
import sys, numpy as np, pandas as pd
print(sys.version)              # Python 版本
print("NumPy", np.__version__, "Pandas", pd.__version__)
```

输出

```
3.12.7 (tags/v3.12.7:0b05ead, ...)
NumPy 2.5.3  Pandas 3.0.5
```

要求 Python ≥ 3.7，且 NumPy / Pandas 能正常导入；版本号因环境而异。

四、实验步骤

任务一：环境与语法热身

1）编写函数，实现摄氏度转华氏温度，F = C*9/5 + 32；

2）编写程序：输入分数（0-100），输出对应等级（90以上A，80-89 B，70-79 C，60-69 D，60以下F）；

3）给定销售额列表[120, 880, 9980, 45, 320, 760]，用循环+条件统计超过均值的个数。

任务二：NumPy 基础

1）生成 5×5 随机整数数组（0~100），输出形状、类型、最大/最小值、均值、标准差。

2）对数组进行转置（.T）和重塑为 25 个元素的一维数组（.reshape(-1)）。

3）计算数组每行的均值（axis=1）。

四、实验步骤

任务三：Pandas 数据处理

读取**实验一_销售流水_原始.csv** 数据，做相应任务：

1、读取与概览（使用shape、info、head等函数）；

2、检查是否有重复值，并去重；

3、类型转换与口径归一（比如“金额/数量/类别/时间”列）；

（注：此处只做数值化/归一/解析时间，不要提前 astype('category')，否则步骤5 fillna('未知') 会报 TypeError）

4、数据筛选（按月统计销量；查询amount>1000的订单；query 取 A 店家电子集）；

5、缺失值检测与处理（比如 连续缺失用**中位数**、分类缺失填「**未知**」单独类别）；

6、异常值检测与处理；

7、分组聚合与透视（按门店聚合，得到订单额/均值/笔数）；

8、最后保存结果至本地csv文件。

任务四：数据可视化（选做）

用 Matplotlib 画一张「各门店销售额柱状图」（注意中文不要显示乱码）。

五、实验要点（易错 Top 6）

动手前先过一遍这些坑

- 列表 vs ndarray：NumPy 数组支持向量化，能用向量化就别写 for 循环。
- Jupyter 执行顺序：避免变量被未执行的单元格污染，必要时 Kernel → Restart & Run All。
- inplace 语义：fillna(inplace=True) 改原表且不返回新对象；别再写 df = df.fillna(..., inplace=True)。
- 缺失值方法选择：连续数值用中位数（抗异常）；分类变量缺失填「未知」单独类别（或众数）；缺失率 >80% 考虑删除列。
- 保存 CSV：务必 index=False 防多余行号列；中文用 encoding="utf-8-sig" 防乱码。
- 异常值≠错误值：业务真实的大额订单要保留，删除前先问"业务上讲得通吗"。

清洗主线（8 步）：读取 → 去重 → 类型转换 → 口径归一 → 筛选 → 缺失 → 异常 → 聚合透视 → 保存

六、实验要求与思考题

提交一个完整 .ipynb

- 提交平台：https://grader.hitsz.edu.cn/courses
- 登录方式：统一身份认证
- 截止时间：9月28日 晚24:00，补交按得分80%计算
- 提交内容：所有代码单元格 + 关键步骤 Markdown 说明 + 关键输出（head()、缺失统计、异常筛选结果、聚合/透视输出等）+ 以下4个思考题的回答。

思考题 1：为什么缺失值常用中位数而非均值？结合本数据 amount 的 8 个负值与 3 个离谱极值说明。
思考题 2：IQR 法则与 3σ 法则各适用于什么分布？为什么本课程更推荐 IQR？
思考题 3：NumPy 向量化与 Python 列表循环在内存与速度上有何差异？为什么 pandas 底层依赖 NumPy？
思考题 4：保存 CSV 为什么推荐 index=False 且中文用 utf-8-sig？