

概率论公式总结

一、随机事件与概率

古典概型

$$P(A) = \frac{n(A)}{n(S)}$$

几何概型

$$P(A) = \frac{L(A)}{L(S)}$$

事件的运算

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

$$P(A - B) = P(A) - P(AB)$$

$$P(A) + P(\bar{A}) = 1$$

容斥原理

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k+1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} P(A_{i_1} A_{i_2} \dots A_{i_k}) \right)$$

特别地，当 $A_1, A_2, \dots, A_n$ 互不相容时，有

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

条件概率

$$P(A|B) = \frac{P(AB)}{P(B)}$$

多重条件概率公式

$$P(A_1 A_2 \dots A_n) = P(A_1) P(A_2 | A_1) \dots P(A_n | A_1 A_2 \dots A_{n-1})$$

注：事件运算性质对于条件概率仍成立。

全概率公式

$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i)$$

贝叶斯公式

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

事件独立性

n 个事件相互独立的定义

$$\forall S \subseteq \{1, 2, \cdots, n\}, P\left(\bigcap_{i \in S} A_i\right) = \prod_{i \in S} P(A_i)$$

二、随机变量及其分布

离散型随机变量

描述方式：分布列

$$P\{X = x_i\} = p_i, i = 1, 2, \cdots$$

表格形式

X	x_1	x_2	x_3	$\cdots$
P	p_1	p_2	p_3	$\cdots$

典型的离散型随机变量分布

分布类型	符号	分布列	期望	方差
两点分布	$B(1, p)$	$P\{X = 1\} = p, P\{X = 0\} = 1 - p$	p	$p(1 - p)$
二项分布	$B(n, p)$	$P\{X = k\} = C_n^k p^k (1 - p)^{n - k}$	np	$np(1 - p)$
泊松分布	$P(\lambda)$	$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ
几何分布	$G(p)$	$P\{X = k\} = p(1 - p)^{k - 1}$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$
超几何分布	$H(n, M, N)$	$P\{X = k\} = \frac{C_{N - M}^{n - k} C_M^k}{C_N^n}$	np	$np(1 - p) \frac{N - n}{N - 1}$
负二项分布	$NB(r, p)$	$P\{X = k\} = C_{k - 1}^{r - 1} p^r (1 - p)^{n - r}$	$\frac{r}{p}$	$r \frac{1 - p}{p^2}$

注：对于几何分布，有

$$P(X > n + m | X > n) = P(X > m)$$

若 $X \sim G(p_1), Y \sim G(p_2)$, 则

$$\min\{X, Y\} \sim G(1 - (1 - p_1)(1 - p_2))$$

泊松定理

设 $X_n \sim B(n, p_n)$, $\lim_{n \rightarrow \infty} np_n = \lambda$, 则对于任意非负整数 k , 有

$$P(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

应用要求: $n \geq 100, p_n \leq 0.1, np_n$ 不太大。

分布函数

$$F(x) = P(X \leq x)$$

性质

$$0 \leq F(x) \leq 1$$

$$\forall x_1 < x_2, F(x_1) \leq F(x_2)$$

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1$$

$$F(x_0^+) = F(x_0)$$

连续性随机变量

描述方式: 分布函数、概率密度函数

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

$$f(x) = F'(x)$$

性质

$$f(x) \geq 0$$

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

$$P(x_1 < X \leq x_2) = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(t) dt$$

典型的连续型随机变量分布

分布类型	符号	概率密度函数	分布函数	期望	方差
均匀分布	$U(a,b)$	$\begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{others} \end{cases}$	$\begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布	$E(\lambda)$	$\begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$	$\begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布	$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$\int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt = \Phi(\frac{x-\mu}{\sigma})$	μ	σ^2

注：

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

对于指数分布，有

$$P(X > t + s | X > t) = P(X > s)$$

若 $X_1, X_2, \cdots, X_n$ 相互独立且均服从参数为 λ 的指数分布，则

$$2\lambda \sum_{i=1}^n X_i \sim \chi^2(2n)$$

若 $X \sim E(\lambda_1), Y \sim E(\lambda_2)$ ，则

$$\min\{X, Y\} \sim E(\lambda_1 + \lambda_2)$$

对于正态分布，若 $X_1, X_2, \cdots, X_n$ 相互独立，则

$$\sum_{i=1}^n c_i X_i \sim N(\sum_{i=1}^n c_i \mu_i, \sum_{i=1}^n c_i^2 \sigma_i^2)$$

求 $Y = g(X)$ 的分布函数及概率密度函数

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y)$$

$$f_Y(y) = \frac{dF_Y(y)}{dy}$$

三、多维随机变量及其分布

联合分布函数

$$F(x, y) = P(X \leq x, Y \leq y)$$

性质

$$0 \leq F(x, y) \leq 1$$

$$\forall x_1 < x_2, F(x_1, y) \leq F(x_2, y), \forall y_1 < y_2, F(x, y_1) \leq F(x, y_2)$$

$$F(-\infty, -\infty) = F(-\infty, y) = F(x, -\infty) = 0, F(+\infty, +\infty) = 1$$

$$F(x_0^+, y) = F(x_0, y), F(x, y_0^+) = F(x, y_0)$$

$$P\{a < X \leq b, c < Y \leq d\} = F(b, d) - F(b, c) - F(a, d) + F(a, c) \in [0, 1]$$

边缘分布

$$F_X(x) = P(X \leq x) = F(x, +\infty) = \lim_{y \rightarrow +\infty} F(x, y)$$

$$F_Y(y) = P(Y \leq y) = F(+\infty, y) = \lim_{x \rightarrow +\infty} F(x, y)$$

条件分布

$$F_{X|Y}(x|y) = P(X \leq x|Y = y) = \lim_{\varepsilon \rightarrow 0^+} \frac{P\{X \leq x, y - \varepsilon < Y \leq y + \varepsilon\}}{P\{y - \varepsilon < Y \leq y + \varepsilon\}}$$

$$(\forall \varepsilon > 0, P\{y - \varepsilon < Y \leq y + \varepsilon\} > 0)$$

二维离散型随机变量

描述方式：分布列

$$P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$$

边缘分布

$$p_{i\cdot} = P\{X = x_i\} = \sum_{j=1}^m p_{ij}$$

$$p_{\cdot j} = P\{Y = y_j\} = \sum_{i=1}^n p_{ij}$$

表格形式

$X \setminus Y$	y_1	y_2	$\cdots$	$p_{i\cdot}$
x_1	p_{11}	p_{12}	$\cdots$	$p_{1\cdot}$
x_2	p_{21}	p_{22}	$\cdots$	$p_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$p_{\cdot j}$	$p_{\cdot 1}$	$p_{\cdot 2}$	$\cdots$	1

条件分布

$$P\{X = x_i|Y = y_j\} = \frac{p_{ij}}{p_{\cdot j}}, P\{Y = y_j|X = x_i\} = \frac{p_{ij}}{p_{i\cdot}}$$

二维连续型随机变量

描述方式：联合分布函数、联合概率密度函数

$$F(x,y)=\int_{-\infty}^x\int_{-\infty}^yf(u,v)\mathrm{d}u\mathrm{d}v$$

性质

$$\begin{aligned}f(x,y)&\geq 0\\ \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}f(x,y)\mathrm{d}x\mathrm{d}y&=1\\ P\{(X,Y)\in D\}&=\iint_Df(x,y)\mathrm{d}x\mathrm{d}y\end{aligned}$$

边缘分布

$$\begin{aligned}F_X(x)&=F(x,+\infty)=\int_{-\infty}^x\left[\int_{-\infty}^{+\infty}f(u,v)\mathrm{d}v\right]\mathrm{d}u\\ f_X(x)&=F'_X(x)=\int_{-\infty}^{+\infty}f(x,y)\mathrm{d}y\end{aligned}$$

同理

$$f_Y(y)=F'_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\mathrm{d}x$$

条件分布

$$\begin{aligned}F_{X|Y}(x|y)&=\int_{-\infty}^x\frac{f(s,y)}{f_Y(y)}\mathrm{d}s, f_Y(y)>0\\ f_{X|Y}(x|y)&=F'_{X|Y}(x|y)=\frac{f(x,y)}{f_Y(y)}, f_Y(y)>0\end{aligned}$$

$$\Rightarrow f(x, y) = f_{X|Y}(x|y)f_Y(y)$$

随机变量的独立性

随机变量 X 和 Y 相互独立的定义

$$\forall x, y \in \mathbb{R},$$

$$P\{X \leq x, Y \leq y\} = P\{X \leq x\}P\{Y \leq y\}$$

即

$$F(x, y) = F_X(x)F_Y(y)$$

离散型随机变量相互独立的条件

$$\forall i, j$$

$$P\{X = x_i, Y = y_j\} = p_{ij} = p_{i \cdot} p_{\cdot j}$$

连续型随机变量相互独立的条件

$$\forall x, y \in \mathbb{R},$$

$$f(x, y) = f_X(x)f_Y(y)$$

二维均匀分布

$$f(x, y) = \begin{cases} \frac{1}{A}, & (x, y) \in D \\ 0, & \text{others} \end{cases}$$

$$P\{(X, Y) \in D\} = \frac{S_D}{S_G}$$

二维正态分布

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \left(\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} \right) \right]$$

记为

$$(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$$

性质

$$X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$$

$$aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2 + 2ab\rho\sigma_1\sigma_2)$$

当 $\begin{vmatrix} a & b \\ c & d \end{vmatrix} \neq 0$ 时, $(aX + bY, cX + dY)$ 服从二维正态分布。

X 与 Y 相互独立的充要条件为

$$\rho = 0$$

求 $Z = g(X, Y)$ 的分布

(1) 离散型

$$P(Z = z_k) = P\{g(X, Y) = z_k\} = \sum_{g(x_i, y_j) = z_k} p_{ij}$$

(2) 连续型

$$F_Z(z) = P(Z \leq z) = P\{g(X, Y) \leq z\} = \iint_{g(x, y) \leq z} f(x, y) dx dy$$

$$f_Z(z) = \frac{dF_Z(z)}{dz}$$

特别地,

① 求 $Z = X + Y$ 的分布

$$F_Z(z) = P(Z \leq z) = P\{X + Y \leq z\} = \iint_{x+y \leq z} f(x, y) dx dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{z-x} f(x, y) dx dy$$

$$f_Z(z) = \frac{dF_Z(z)}{dz} = \int_{-\infty}^{+\infty} f(x, z-x) dx = \int_{-\infty}^{+\infty} f(z-y, y) dy$$

当 X 和 Y 相互独立时,

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy$$

记为

$$f_Z = f_X * f_Y$$

② 求 $Z = \max\{X, Y\}$ 和 $Z = \min\{X, Y\}$ 的分布

对于 $Z = \max\{X, Y\}$,

$$P(Z \leq z) = P\{X \leq z, Y \leq z\}$$

即

$$F_Z(z) = F_{X,Y}(z, z)$$

当 X 和 Y 相互独立时,

$$F_Z(z) = F_{(X,Y)}(z, z) = F_X(z)F_Y(z)$$

同理, 对于 $Z = \min\{X, Y\}$, 当 X 和 Y 相互独立时,

$$F_Z(z) = 1 - (1 - F_X(z))(1 - F_Y(z))$$

(3) X 为离散型, Y 为连续型

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P\{g(X, Y) \leq z\} \\ &= \sum_{i=1}^n P(X = x_i)P\{g(X, Y) \leq z | X = x_i\} \\ &= \sum_{i=1}^n p_i P\{g(x_i, Y) \leq z | X = x_i\} \end{aligned}$$

四、随机变量的数字特征

期望

(1) 离散型

$$\begin{aligned} \mathbb{E}(X) &= \sum_{i=1}^n x_i p_i \\ \mathbb{E}(g(X)) &= \sum_{i=1}^n g(x_i) p_i \\ \mathbb{E}(g(X, Y)) &= \sum_{i=1}^n \sum_{j=1}^m g(x_i, y_j) p_{ij} \end{aligned}$$

注: 当 n 或 m 趋于 ∞ 时, 期望存在需保证级数绝对收敛。

(2) 连续型

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{+\infty} x f_X(x) dx \\ \mathbb{E}(g(X)) &= \int_{-\infty}^{+\infty} g(x) f_X(x) dx \\ \mathbb{E}(g(X, Y)) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f_{X,Y}(x, y) dx dy \end{aligned}$$

(3) 期望的性质

$$\mathbb{E}\left(\sum_{i=1}^n c_i X_i\right) = \sum_{i=1}^n c_i \mathbb{E}(X_i)$$

X 与 Y 不相关, 等价于

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$$

注: X 与 Y 相互独立 $\Rightarrow X$ 和 Y 不相关 $\Leftrightarrow E(XY) = E(X)E(Y) \Leftrightarrow \text{Cov}(X, Y) = 0$

方差与标准差

$$\mathbb{D}(X) = \mathbb{E}[(X - \mathbb{E}(X))^2] = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$$

$$\Rightarrow \mathbb{E}(X^2) = [\mathbb{E}(X)]^2 + \mathbb{D}(X)$$

$$\sigma(X) = \sqrt{\mathbb{D}(X)}$$

性质

$$\mathbb{D}\left(\sum_{i=1}^n (c_i X_i + b_i)\right) = \sum_{i=1}^n c_i^2 \mathbb{D}(X_i)$$

X 与 Y 不相关, 等价于

$$\mathbb{D}(X \pm Y) = \mathbb{D}(X) + \mathbb{D}(Y)$$

矩

k 阶原点矩: $\mathbb{E}(X^k)$

k 阶中心矩: $\mathbb{E}[(X - \mathbb{E}(X))^k]$

X 和 Y 的 $k+l$ 阶混合矩: $\mathbb{E}(X^k Y^l)$

X 和 Y 的 $k+l$ 阶混合中心矩: $\mathbb{E}\{[X - \mathbb{E}(X)]^k [Y - \mathbb{E}(Y)]^l\}$

协方差

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

性质

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

$$\text{Cov}(X, X) = \mathbb{D}(X)$$

$$\mathbb{D}(X \pm Y) = \mathbb{D}(X) + \mathbb{D}(Y) \pm 2\text{Cov}(X, Y)$$

$$\text{Cov}(X \pm Y, Z) = \text{Cov}(X, Z) \pm \text{Cov}(Y, Z)$$

$$\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$$

相关系数

若 $\mathbb{D}(X)\mathbb{D}(Y) \neq 0$ 则

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{D}(X)\mathbb{D}(Y)}}$$

否则

$$\rho_{XY} = 0$$

性质

$$\rho_{XY} \in [-1, 1]$$

$$|\rho_{XY}| = 1 \Leftrightarrow \exists a, b, P\{Y = aX + b\} = 1$$

五、大数定律和中心极限定理

马尔科夫不等式与切比雪夫不等式

马尔科夫不等式

$$P(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$$

令 $X = [X - \mathbb{E}(X)]^2, a = \varepsilon^2$ 得

切比雪夫不等式

$$P(|X - \mathbb{E}(X)| \geq \varepsilon) \leq \frac{\mathbb{D}(X)}{\varepsilon^2} \Rightarrow P(|X - \mathbb{E}(X)| < \varepsilon) > 1 - \frac{\mathbb{D}(X)}{\varepsilon^2}$$

依概率收敛的定义

设 $X_1, X_2, \dots$ 是一个随机序列, 若对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|X_n - A| < \varepsilon) = 1$$

则称 $X_1, X_2, \dots$ 依概率收敛于 A , 记作 $X_n \xrightarrow{P} A$ 。

大数定律

切比雪夫大数定律

设 $X_1, X_2, \dots$ 为两两不相关的随机变量序列, 存在常数 C 使得 $\max\{\mathbb{D}(X_i)\} \leq C$, 则

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}(X_i)) \xrightarrow{P} 0$$

伯努利大数定律

设 $X_i \sim B(i, p), i = 1, 2, \dots$ 则

$$\frac{X_n}{n} \xrightarrow{P} p$$

辛钦大数定律

设 $X_1, X_2, \dots$ 独立同分布，且 $\mathbb{E}(X_i) = \mu$ ，则

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

中心极限定理

棣莫弗-拉普拉斯中心极限定理

设 $X_i \sim B(i, p), i = 1, 2, \dots$ 则 $\forall x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P\left\{\frac{X_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \Phi(x)$$

换言之，对于充分大的 n ，可认为

$$\frac{X_n - np}{\sqrt{np(1-p)}} \sim N(0, 1)$$

也即

$$X_n \sim N(np, np(1-p))$$

列维-林德伯格中心极限定理

设 $X_1, X_2, \dots$ 独立同分布，且 $\mathbb{E}(X_i) = \mu, \mathbb{D}(X_i) = \sigma^2$ ，则 $\forall x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P\left\{\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x\right\} = \Phi(x)$$

换言之，对于充分大的 n ，可认为

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

也即

$$\sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2)$$

六、数理统计

样本的分布

$$F_n(x_1, x_2, \cdots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$$

对于连续型随机变量

$$f_n(x_1, x_2, \cdots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$$

对于离散型随机变量

$$P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n\} = \prod_{i=1}^n P\{X_i = x_i\}$$

统计量

$$T = T(X_1, X_2, \cdots, X_n)$$

注：统计量是一个随机变量；统计量是随机样本的函数。

常用统计量

样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^k$$

性质

$$\mathbb{E}(\overline{X}) = \mathbb{E}(X) = \mu$$

$$\mathbb{D}(\overline{X}) = \frac{1}{n} \mathbb{D}(X) = \frac{\sigma^2}{n}$$

$$\mathbb{E}(S^2) = \mathbb{D}(X) = \sigma^2$$

$$\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mathbb{E}(X^k)$$

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \right] = \sigma^2$$

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2 \right] = \frac{n-1}{n} \sigma^2$$

常用统计抽样分布

χ^2 分布

若 $X_i \sim N(0, 1), i = 1, 2, \dots, n$ 则

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2 \sim \chi^2(n)$$

性质

$$P\{\chi^2 > \chi_\alpha^2(n)\} = \alpha$$

$$\mathbb{E}(\chi^2) = n, \mathbb{D}(\chi^2) = 2n$$

$$\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$$

t 分布

若 $X \sim N(0, 1), Y \sim \chi^2(n)$ 则

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n)$$

性质

$$f_T(x)=f_T(-x)$$

$$P\{T>t_{\alpha}(n)\}=\alpha$$

$$P\{|T|>t_{\frac{\alpha}{2}}(n)\}=\alpha$$

$$t_{1-\alpha}(n)=-t_{\alpha}(n)$$

***F* 分布**

若 $X\sim\chi^2(n_1),Y\sim\chi^2(n_2)$ 则

$$F=\frac{X/n_1}{Y/n_2}\sim F(n_1,n_2)$$

性质

$$P\{F>F_{\alpha}(n_1,n_2)\}=\alpha$$

$$F\sim F(n_1,n_2)\Rightarrow\frac{1}{F}\sim F(n_2,n_1)$$

$$F_{1-\alpha}(n_1,n_2)=\frac{1}{F_{\alpha}(n_2,n_1)}$$

正态总体的抽样分布

性质

$\overline{X}$ 与 S^2 相互独立，且

$$\overline{X}\sim N(\mu,\frac{\sigma^2}{n}),U=\frac{\overline{X}-\mu}{\sigma/\sqrt{n}}\sim N(0,1)$$

$$\chi^2=\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$$

$$T=\frac{\overline{X}-\mu}{S/\sqrt{n}}\sim t(n-1)$$

$$\chi^2=\frac{1}{\sigma^2}\sum_{i=1}^n(X_i-\mu)^2\sim\chi^2(n)$$

若为两个正态总体

$$\overline{X}-\overline{Y}\sim N(\mu_1-\mu_2,\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2})$$

$$U = \frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

当 $\sigma_1 = \sigma_2$ 时

$$T = \frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{S_\omega \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

其中

$$S_\omega^2 = \frac{(n_1 - 1)\sigma_1^2 + (n_2 - 1)\sigma_2^2}{n_1 + n_2 - 2}$$

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

七、参数估计

无偏估计

$$\mathbb{E}(\hat{\theta}) = \theta$$

更有效估计

若

$$\mathbb{E}(\hat{\theta}_1) = \mathbb{E}(\hat{\theta}_2)$$

且

$$\mathbb{D}(\hat{\theta}_1) \leq \mathbb{D}(\hat{\theta}_2)$$

则称 $\hat{\theta}_1$ 为 $\hat{\theta}_2$ 的更有效估计。

相合估计

$$\hat{\theta}_n \xrightarrow{P} \theta$$

判断方法

- (1) 大数定律
- (2) 切比雪夫不等式
- (3) 求 $\hat{\theta}_n$ 的分布函数，根据定义计算

即 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1$$

矩估计

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l = \mathbb{E}(X^l)$$

最大似然估计

离散型

设 $P\{X = a_i\} = p(a_i; \theta_1, \theta_2, \cdots, \theta_k)$ 则

$$L(\theta_1, \theta_2, \cdots, \theta_k) = P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n\} = \prod_{i=1}^n p(a_i; \theta_1, \theta_2, \cdots, \theta_k)$$

连续型

设 $f(x; \theta_1, \theta_2, \cdots, \theta_k)$ 为概率密度函数， 则

$$L(\theta_1, \theta_2, \cdots, \theta_k) = P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n\} = \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \cdots, \theta_k)$$

最大似然估计量 $\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k$ 为使 $L(\theta_1, \theta_2, \cdots, \theta_k)$ 取最大值的参数值（求驻点或其它方法）。

区间估计

一个正态总体参数的区间估计

参数	$1 - \alpha$ 置信区间
σ 已知，求 μ	$\left(\overline{X} - u_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \overline{X} + u_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right)$
σ 未知，求 μ	$\left(\overline{X} - t_{\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}}, \overline{X} + t_{\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}}\right)$
μ 未知，求 σ^2	$\left(\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}\right)$

八、神秘技巧

概率密度变换公式

一元

设随机变量 X 的概率密度函数为 $f_X(x)$ ， $Y = g(X)$ ，且 $g(x)$ 可导且单调，令 $h(y) = g^{-1}(y)$ ，则 Y 的概率密度函数为

$$f_Y(y)=f_X(x)\left|\frac{\mathrm{d} x}{\mathrm{d} y}\right|=f_X(h(y))\left|\frac{\mathrm{d} h}{\mathrm{d} y}\right|$$

二元

设二维连续型随机向量 (X, Y) 具有**联合概率密度函数** $f_{XY}(x, y)$,

我们构造一个新的二维随机向量 (U, V) ，它们是由 (X, Y) 通过一个**一一对应的、可逆的变换**得到的：

$$\begin{cases} U=g_1(X, Y) \\ V=g_2(X, Y) \end{cases}$$

并且这个变换存在逆变换：

$$\begin{cases} X=h_1(U, V) \\ Y=h_2(U, V) \end{cases}$$

那么， (U, V) 的联合概率密度函数 $f_{UV}(u, v)$ 为：

$$f_{UV}(u, v)=f_{XY}\big(h_1(u, v),\, h_2(u, v)\big)\cdot |J|$$

其中， J 是**逆变换的雅可比行列式**，其绝对值为：

$$\begin{aligned} |J| &= \left|\det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix}\right| = \left|\frac{\partial x}{\partial u} \cdot \frac{\partial y}{\partial v} - \frac{\partial x}{\partial v} \cdot \frac{\partial y}{\partial u}\right| \\ &= \left|\frac{\partial h_1(u, v)}{\partial u} \cdot \frac{\partial h_2(u, v)}{\partial v} - \frac{\partial h_1(u, v)}{\partial v} \cdot \frac{\partial h_2(u, v)}{\partial u}\right| \end{aligned}$$

Γ 函数

$$\Gamma(s+1)=\int_0^{+\infty}x^se^{-x}\mathrm{d} x=s\Gamma(s)$$

$$\Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}$$

$$\Gamma(n+1)=n!\,(n\in\mathbb{N})$$

$\max\{X, Y\}$ 与 $\min\{X, Y\}$

$$\max\{X, Y\}=\frac{X+Y+|X-Y|}{2}$$

$$\min\{X, Y\} = \frac{X + Y - |X - Y|}{2}$$

可再生性

泊松分布的可再生性

设 $X_1, X_2, \dots, X_n$ 是独立的泊松随机变量 $X_i \sim P(\lambda_i)$, 则

$$X_1 + X_2 + \dots + X_n \sim P(\lambda_1 + \lambda_2 + \dots + \lambda_n)$$

二项分布的可再生性

设 $X_1, X_2, \dots, X_n$ 是独立的二项随机变量 $X_i \sim B(n_i, p)$, 则

$$X_1 + X_2 + \dots + X_n \sim B(n_1 + n_2 + \dots + n_n, p)$$

正态分布的可再生性

设 $X_1, X_2, \dots, X_n$ 是独立的正态随机变量 $X_i \sim N(\mu_i, \sigma_i^2)$, 则

$$X_1 + X_2 + \dots + X_n \sim N(\mu_1 + \mu_2 + \dots + \mu_n, \sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)$$

指示变量法

基本思想

将随机计数变量 X 表示为一系列**指示变量 (0-1变量)** 的和, 每个指示变量对应一个基本单元是否满足特定条件, 从而利用线性性质简化期望与方差计算。

定义

对于事件 A , 定义

$$I_A = \begin{cases} 1, & \text{若 } A \text{ 发生} \\ 0, & \text{否则} \end{cases}$$

称 I_A 为事件 A 的**指示变量**。

基本性质:

期望 $E(I_A) = P(A)$

方差 $\text{Var}(I_A) = P(A)[1 - P(A)]$

一般步骤

$$X = \sum_{i=1}^n I_{A_i},$$

$$E(X) = \sum_{i=1}^n P(A_i).$$

单个方差

$$\mathrm{Var}(I_{A_i}) = P(A_i)[1 - P(A_i)]$$

.
协方差
对 $i \neq j$,

$$\mathrm{Cov}(I_{A_i}, I_{A_j}) = P(A_i \cap A_j) - P(A_i)P(A_j).$$

总方差

$$\mathrm{Var}(X) = \sum_{i=1}^n \mathrm{Var}(I_{A_i}) + 2 \sum_{1 \leq i < j \leq n} \mathrm{Cov}(I_{A_i}, I_{A_j}).$$